

HEC Montréal

## **Reconnaissance d'émotion à travers des données textuelles**

Travail présenté à

Jian Tang

Dans le cadre du cours

Apprentissage automatique II

MATH 60630

**par**

**Mustapha Bouhsen 11321500**

**Idrissa Coulibaly 11119684**

**Maya Otomo-Lauzon 11282915**

**Hichem Sahraoui 11257735**

**26 avril 2023**

## Tables des matières

1. Introduction générale.....	1
2. Revue de littérature .....	1
2.1 Naïve Bayes .....	1
2.2 Réseaux de neurones .....	2
2.3 Transformers .....	2
3. Méthodologie et modèles.....	3
3.1 Méthodologie .....	3
3.2 Mise en œuvre des modèles .....	3
4. Résultats expérimentaux.....	5
4.1 Présentation et interprétation des résultats.....	5
4.2 Analyse et discussion.....	6
5. Conclusion générale et perspectives .....	6
Références bibliographiques.....	8

# 1. Introduction générale

Avec l'avènement des réseaux sociaux, la quantité de données textuelles disponibles augmentent de manière exponentielle. Chaque message, publication ou commentaire représentent une nouvelle source d'informations textuelles. Les mots contenus dans ces textes sont utilisés pour transmettre des idées, mais également pour exprimer des sentiments. C'est pourquoi la reconnaissance des émotions sous-jacentes dans ces textes est devenue un enjeu majeur. Cette reconnaissance est un outil précieux pour aider à la prise de décisions dans de nombreux domaines tels que le marketing, la finance ou encore la politique.

Dans cette étude, nous explorerons différents modèles prédictifs couramment utilisés dans la littérature pour maximiser la performance de la reconnaissance des émotions. Nous testerons les modèles de Naïve Bayes, de réseaux de neurones et de transformers en ajustant plusieurs hyperparamètres, afin de comparer leur performance et de déterminer le modèle le plus adapté à notre problématique.

## 2. Revue de littérature

### 2.1 Naïve Bayes

Les Naïve Bayes sont une famille de modèles statistiques basés sur le théorème de Bayes, qui sont largement utilisés dans la classification de textes en raison de leur simplicité et de leur efficacité. Cette approche suppose que toutes les caractéristiques sont indépendantes les unes des autres, ce qui est une hypothèse réductrice, mais qui peut souvent être acceptable pour des tâches de classification de texte. Les Naïve Bayes ont été utilisés dans de nombreuses applications, notamment dans la classification de pourriels, la reconnaissance de la langue et la classification de documents.

Dans leur article "A Comparison of Event Models for Naive Bayes Text Classification" publié en 1998, McCallum et Nigam ont comparé différentes représentations de caractéristiques de texte pour la classification de texte à l'aide de Naïve Bayes. Ils ont comparé des modèles d'événements binaires, multivariés et multinomiaux, et ont constaté que le modèle multinomial était le plus efficace pour la classification de texte. Ils ont également montré que l'ajout de lissage améliore la

performance de la classification en traitant les cas où certaines caractéristiques sont manquantes dans les données d'entraînement.

Bien que les modèles de Naïve Bayes ne soient pas aussi performants que les nouveaux modèles de pointe utilisés aujourd'hui, ils représentent tout de même une méthode intéressante à explorer pour notre étude.

## 2.2 Réseaux de neurones

Les réseaux de neurones sont devenus populaires pour la classification de texte en raison de leur capacité à modéliser des relations complexes entre les données d'entrée et de sortie. Plusieurs auteurs ont proposé des variantes de réseaux de neurones pour la classification de texte. Par exemple, Kim a proposé en 2014 un modèle de réseau de neurones convolutifs pour la classification de texte dans son article "Convolutional Neural Networks for Sentence Classification", qui utilise des filtres de convolution pour extraire des caractéristiques locales des phrases. En 2016, Yang et al. ont proposé un modèle de réseau de neurones récurrents pour la classification de texte dans leur article "Hierarchical Attention Networks for Document Classification", qui utilise une attention hiérarchique pour identifier les parties importantes des documents.

Les variantes proposées par ces auteurs ont montré des performances prometteuses dans différents domaines de classification de texte, ce qui montre la pertinence et la flexibilité des réseaux de neurones pour la classification de texte.

## 2.3 Transformers

Les transformers sont une technique de pointe pour la classification de texte en raison de leur capacité à modéliser des relations complexes entre les données d'entrée et de sortie. Ils ont été introduits en 2017 par Vaswani et al. dans leur article "Attention Is All You Need". Les modèles basés sur les transformers sont capables d'apprendre des représentations de caractéristiques de texte des données d'entrée en utilisant une attention multitête pour modéliser les relations entre les caractéristiques de texte. Ces modèles peuvent être préentraînés sur de grands ensembles de données non annotées, puis ajustés pour une tâche spécifique, ce qui peut améliorer considérablement la performance de la classification.

En 2018, Devlin et al. ont proposé un modèle de classification de texte utilisant les transformers dans leur article "BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding", qui utilise un entraînement non supervisé pour apprendre des représentations de caractéristiques de texte à partir de grandes quantités de données non annotées.

Depuis, plusieurs variantes de BERT ont été proposées, telles que RoBERTa (Liu et al., 2019), qui ont considérablement amélioré les performances de classification de texte. De plus, de nouvelles architectures de transformers, comme GPT (Brown et al., 2020), ont également été proposées et sont aujourd'hui considérées comme l'état de l'art en matière de tâches pour le traitement du langage naturel.

### 3. Méthodologie et modèles

#### 3.1 Méthodologie

Pour mener cette étude, nous avons exploité un ensemble de données textuelles étiquetées pour réaliser la classification des émotions en utilisant différents modèles prédictifs. L'ensemble de données sélectionné comprenait 207 505 exemples de textes, chacun étiqueté comme "triste" ou "heureux". Afin de prétraiter les données, nous avons effectué une exploration de données et un nettoyage de texte, en utilisant différentes techniques telles que la suppression de caractères non désirés et la tokenisation. Les données ont ensuite été divisées en un ensemble d'entraînement et un ensemble de validation, avec une proportion de 80/20. Nous avons entraîné des modèles basés sur les Naïve Bayes, les réseaux de neurones et les transformers et avons effectué une validation croisée pour tester plusieurs hyperparamètres et trouver la configuration optimale pour chaque modèle. Pour évaluer la qualité des modèles et les comparer, nous avons utilisé l'*accuracy* comme mesure de performance. Pour implémenter Naïve Bayes et les réseaux de neurones, nous avons utilisé la bibliothèque scikit-learn, tandis que les modèles basés sur les transformers ont été implémentés en utilisant les bibliothèques transformers et PyTorch.

#### 3.2 Mise en œuvre des modèles

Pour l'entraînement des modèles Naïve Bayes, nous avons fait varier le paramètre de lissage  $\alpha$ . Ce paramètre permet de régulariser les estimations de probabilité en cas de données rares ou

manquantes dans l'ensemble d'entraînement. Pour la validation croisée, nous avons utilisé les valeurs suivantes du paramètre  $\alpha = \{0.5, 0.75, 1, 1.25, 1.5, 10\}$ .

Pour l'entraînement des modèles de réseaux de neurones, nous avons fait varier le paramètre de régularisation  $\lambda$ , ainsi que le taux d'apprentissage  $\alpha$ . Le paramètre de régularisation contrôle la complexité du modèle en ajoutant une pénalité sur les poids du modèle pendant l'entraînement alors que le taux d'apprentissage représente la taille du pas à chaque itération en se déplaçant vers la direction qui minimise la fonction de perte. Pour la validation croisée, nous avons utilisé les valeurs suivantes des deux paramètres :  $\lambda = \{0.01, 0.1, 1\}$  et  $\alpha = \{0.001, 0.01, 0.1\}$ .

Pour l'entraînement des modèles de transformers, nous avons testé plusieurs architectures différentes. Nous avons d'abord implémenté les modèles préentraînés tels quels, puis les avons réentraîné sur nos données afin de comparer leur capacité de généralisation. Nous avons essayé les modèles suivants : `distilbert-base-uncased-finetuned-sst-2-english`, `distilbert-base-uncased`, `sentiment-roberta-large-english` et `distilroberta-base`.

## 4. Résultats expérimentaux

### 4.1 Présentation et interprétation des résultats

Les résultats de la validation croisée pour les trois modèles sont présentés dans le tableau suivant.

Pour chacun des modèles, la performance maximale atteinte est identifiée en gras.

**Tableau 4.1 : Performance des trois modèles sur l'ensemble test**

Modèle		Performance sur données test	
Naïve Bayes			
$\alpha = 0.5$		<b>0.5124</b>	
$\alpha = 0.75$		0.5114	
$\alpha = 1$		0.5114	
$\alpha = 1.25$		0.5113	
$\alpha = 1.5$		0.5104	
$\alpha = 10$		0.5072	
Réseaux de neurones			
$\lambda = 0.01$	$\alpha = 0.001$	0.4718	
	$\alpha = 0.01$	0.4794	
	$\alpha = 0.1$	0.4798	
$\lambda = 0.1$	$\alpha = 0.001$	<b>0.4932</b>	
	$\alpha = 0.01$	0.4901	
	$\alpha = 0.1$	0.4761	
$\lambda = 1$	$\alpha = 0.001$	0.4931	
	$\alpha = 0.01$	0.4687	
	$\alpha = 0.1$	0.4652	
Transformers			
Architecture		Sans entraînement	Avec réentraînement
distilbert-base-uncased-finetuned-sst-2-english		0.7536	<b>0.9778</b>
distilbert-base-uncased		0.4966	0.8000
sentiment-roberta-large-english		<b>0.7748</b>	0.9652
distilroberta-base		0.5270	0.9768

## 4.2 Analyse et discussion

Les différents modèles de Naïve Bayes produisent des résultats similaires avec une performance variant entre 51.24% et 50.72%. Il est intéressant de remarquer qu'un paramètre de lissage plus petit amène une légère augmentation de la performance. Ces faibles résultats peuvent être attribués à l'hypothèse naïve selon laquelle toutes les caractéristiques sont indépendantes les unes des autres, ce qui n'est probablement pas adéquat pour notre tâche de reconnaissance d'émotion. En effet, les émotions exprimées dans une phrase peuvent être liées aux mots utilisés, à l'ordre de ceux-ci ou encore à la syntaxe de la phrase, rendant l'hypothèse d'indépendance erronée.

Les résultats obtenus avec les modèles basés sur les réseaux de neurones ont une performance légèrement inférieure aux modèles de Naïve Bayes avec une *accuracy* atteignant près 50% sur l'ensemble de test. Nous notons également une plus grande variabilité dans les résultats qu'avec les modèles de Naïve Bayes. Un plus grand nombre de paramètres et la méthode d'optimisation peuvent expliquer cette variabilité. La faible performance des réseaux de neurones peut être due à une variété de facteurs, tels que la taille et la qualité de l'ensemble de données, la complexité des modèles et les hyperparamètres utilisés pour l'entraînement.

Dans l'ensemble, les modèles basés sur les transformers performant mieux que les modèles de Naïve Bayes et de réseaux de neurones. Les résultats montrent que le réentraînement des modèles améliore considérablement les performances pour la reconnaissance d'émotion, avec en moyenne une augmentation de 29% de l'*accuracy* entre les modèles préentraînés et réentraînés.

## 5. Conclusion générale et perspectives

Les modèles probabilistes comme Naïve Bayes ont des performances inférieures à celles des modèles complexes d'apprentissage profond, en particulier pour des tâches de classification de texte complexes, car ceux-ci ont été développés pour capturer des relations de plus haut niveau entre les caractéristiques de texte, permettant une classification plus précise des émotions.

Malgré le fait que les réseaux de neurones sont capables de modéliser des relations plus complexes entre les caractéristiques de texte que les modèles probabilistes, leur performance pour la reconnaissance d'émotion n'a pas été meilleure. Il peut être intéressant d'explorer d'autres architectures de réseaux de neurones tels que les réseaux de neurones convolutifs ou les réseaux



de neurones récurrents qui pourraient capturer des relations de plus haut niveau entre les caractéristiques de texte, ce qui peut aider à améliorer les performances de reconnaissance d'émotion.

Bien que les transformers permettent d'obtenir des résultats supérieurs par rapport aux autres modèles et peuvent atteindre une *accuracy* de plus de 95%, leur implémentation peut nécessiter des ressources de calcul et de stockage importantes. Il peut alors être intéressant d'utiliser des modèles préentraînés qui produisent des résultats tout de même raisonnables et qui permettent d'éviter certains enjeux liés à l'entraînement de modèles lourds.

## Références bibliographiques

- Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., ... & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33.
- Cheela, S. (2023). Text Emotion Recognition. Récupéré le 5 mars 2023 de <https://www.kaggle.com/datasets/shreejitcheela/text-emotion-recognition>
- Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of the Annual Conference of the North American Chapter of the Association for Computational Linguistics*, 1, 4171-4186.
- Kim, Y. (2014). Convolutional Neural Networks for Sentence Classification. *Proceedings of the Conference on Empirical Methods in Natural Language Processing*, 1, 1746-1751.
- Liu, Y., Ott, M., Goyal, N., Du, J., Joshi, M., Chen, D., ... & Lewis, M. (2019). RoBERTa: A robustly optimized BERT pretraining approach. *arXiv preprint arXiv:1907.11692*.
- McCallum, A., & Nigam, K. (1998). A comparison of event models for Naive Bayes text classification. *Proceedings of the AAAI/ICML-98 Workshop on Learning for Text Categorization*, 1, 41-48.
- Naive Bayes classifieur. (2023). Wikipédia, l'encyclopédie libre. Récupéré le 24 avril 2023 de [https://en.wikipedia.org/w/index.php?title=Naive\\_Bayes\\_classifieur&oldid=1142602745](https://en.wikipedia.org/w/index.php?title=Naive_Bayes_classifieur&oldid=1142602745)
- Transformeur. (2023). Wikipédia, l'encyclopédie libre. Récupéré le 24 avril 2023 de <http://fr.wikipedia.org/w/index.php?title=Transformeur&oldid=203486672>
- Yang, Z., Yang, D., Dyer, C., He, X., Smola, A., & Hovy, E. (2016). Hierarchical attention networks for document classification. *Proceedings of the 2016 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, 2016*, 1480-1489.